

FNO 在 DFT 中的应用

Kohn–Sham FNO

2026.9.18 组会分享

论文: Learning the Kohn–Sham map with neural operators for quasi-linear scaling density functional theory (Caltech, Anandkumar 组, 2026-08)

开场 (30 秒, 对着封面讲) 大家好, 今天我组会分享一篇 Caltech Anandkumar 组今年 8 月的文章, 标题是 “用神经算子学 Kohn–Sham 映射, 实现准线性标度的 DFT”。

一句话先给大家一个印象: 传统 DFT 每一步都要做一次 “对角化”, 它随电子数**立方**增长, 是几十年的天花板。这篇论文用一个神经网络算子 (FNO) **把对角化那一步替掉**, 让计算变成**准线性**, 最后在一块 GPU 上收敛了 8 万个电子的镁位错。

我今天的讲法分三段: 先讲清楚这里的量子化学原理 (什么是 DFT、为什么会有对角化), 再讲什么是 FNO, 最后讲这篇论文具体是怎么做到、效果如何。我们开始。

1 什么是量子化学计算, 以及 Hohenberg–Kohn 定理

这一页怎么讲 先说我们到底在算什么。化学、材料里一个最基础的问题：**给一堆原子核，它们的电子排成什么样、总能量是多少？**因为材料能不能导电、键有多强、熔点多少，几乎都能从“电子排布 + 总能量”推出来。

那为什么难？最“正确”的写法，是要同时盯住**每一个电子**的位置。 N 个电子就是 $3N$ 个变量，这叫波函数。两个电子才 6 维，几百个电子就是几百维——要在几百维空间里找最小值，存储和计算都是**指数级爆炸**。这就是为什么电子结构算大体系一直卡着。

量子化学在 1964 年有个改变游戏规则的想法：**也许不用那几百维的波函数，一张 3 维的“电子密度”就够了。**密度 $n(\mathbf{r})$ 就是“空间每个点上电子多不多”的一张热力图。固定分辨率下，它的网格点数只随**体积线性**增长，不再随电子数指数增长。

为什么这合法？靠 Hohenberg-Kohn 定理，就两条，大家记这两条就行：

1. **基态能量由密度唯一决定**——给定原子核布局，密度一定，总能量就定了；
2. **基态密度 = 让总能量泛函最小的那个密度**——也就是去“最小化”一个关于密度的函数 $E[n]$ 。

这里插一句“泛函”：普通函数是“吃一个数、吐一个数”，泛函是“**吃一整个函数、吐一个数**”——吃一张密度图，吐一个总能量。

那问题就变成：去最小化 $E[n]$ 这个 3 维的东西，比最小化几百维的波函数容易多了。**但是**——HK 定理只告诉你 $E[n]$ 存在、最小化它就对，**没告诉你它具体长什么样**。这个泛函里有一块我们根本解不出来，就是页面上写的“电子之间的交换关联作用”。所以还得有一个工程化的把戏——这就引出下一页的 Kohn-Sham 方程。

密度 $n(\mathbf{r})$ 是主角；HK 定理 = 能量由密度唯一决定 + 基态密度是最小化 $E[n]$ 得到的；难点： $E[n]$ 里有一块（交换关联）解不出。

2 对角化和 SCF 迭代

Kohn-Sham 的把戏（接上一页）真实电子互相纠缠，算不动。Kohn 和 Sham 1965 年的办法很聪明：**假装电子互不理睬**，再给它们配一根“等效指挥棒”势 v_{KS} ，让假装出来的排布恰好等于真实排布。

“互不理睬”为什么就简单？因为不相互作用时，每个电子可以独立待在自己的轨道里，一个 N 电子问题就拆成 N 个单电子问题。这个假系统满足 Kohn-Sham 方程：

$$\left(-\frac{1}{2}\nabla^2 + v_{\text{KS}}(\mathbf{r})\right)\varphi_p(\mathbf{r}) = \varepsilon_p \varphi_p(\mathbf{r}), \quad n_{\text{out}}(\mathbf{r}) = \sum_p f_p |\varphi_p(\mathbf{r})|^2. \quad (1)$$

左边括号里 $-\frac{1}{2}\nabla^2$ 是动能， v_{KS} 是那根指挥棒； φ_p 是第 p 条轨道， ε_p 是它的能量。第二行是把所有轨道平方、按占据数加起来，得到密度。

指挥棒 v_{KS} 是两块相加：

$$v_{\text{KS}} = v_{\text{ext}} + v_{\text{H}} + v_{\text{xc}}, \quad (2)$$

分别是：原子核的吸引（已知输入）、电子之间互斥的 Hartree 势、剩下解不出的交换关联势。**最关键一点**： v_{KS} 本身依赖密度 n ——因为后面两项都是 n 的泛函。这个“依赖自己”，就把它变成了一个不动点问题。

什么是对角化？第一行那个方程，就是“找矩阵的特征值和特征向量”：把算子作用在一个特殊形状上，结果只是把它放大一个倍数、方向不变。把所有这样的形状找出来，复杂矩阵就变成只有对角线上有数的简单矩阵。对一个 $K \times K$ 的矩阵做完整对角化，经典算法代价是 $O(K^3)$ ，而基的大小 K 随电子数 N 线性增长，所以是 $O(N^3)$ 。

SCF 迭代是什么？就是解那个不动点“猜一个密度 → 建指挥棒 → 对角化 → 叠出新密度 → 混合 → 再来”的循环，直到新旧密度一样：

$$n = \mathcal{G}(v_{\text{KS}}[n]), \quad n^{(i+1)} = (1 - \alpha) n^{(i)} + \alpha n_{\text{out}}^{(i)}. \quad (3)$$

那个加权平均 α 叫混合，作用是“步子别迈太大，别震荡发散”。

瓶颈在哪？循环里每一步算一遍成本：建 Hartree 势 $O(N_g \log N_g)$ 、建 XC 势基本线性、混合线性——**只有对角化是 $O(N^3)$** 。而且它是**每一轮**都要做一次。所以整轮 DFT 的成本 $\approx (O(N^3) \text{ 对角化}) \times (\text{几十轮 SCF})$ 。体系大 10 倍，对角化贵 1000 倍——这就是几十年的天花板。

所以整篇论文的靶子很清楚：把“输入指挥棒 v_{KS} → 输出密度 n_{out} ”这一步（也就是对角化）用一个便宜的东西替掉，其余全保留。问题是——**替谁、学哪个映射**？下一页。

3 消灭对角化这一瓶颈：学习哪一步？

三种候选，本文选哪个“去掉对角化”其实有三种不同的学法。这是这篇论文最核心的判断，我花点时间讲。

先立住前提：对角化这一步，本身就是一个“**指挥棒 $v_{KS} \rightarrow$ 密度 n_{out} (外加动能 T_s)**”的算子，论文记作 G_{KS} 。所以“去对角化” = “找个神经网络 F_θ 替掉它”。悬念在于：这个替法有三种，选错了整个自治就发散。

思路 A：学“逆映射”。传统免轨道 DFT 是直接对密度做能量最小化，它要学的是“**密度 $\rightarrow$ 指挥棒**”这个反方向，也就是把前向算子求逆。为什么“求逆”是病？把前向响应算子 χ_s （指挥棒动一点，密度响应多少）对角化，它有很多**弱模态**——特征值 λ 很小。前向走 χ_s ：误差按 λ 缩放，弱模态把误差**压扁**；求逆走 χ_s^{-1} ：弱模态变成 $1/\lambda$ ，误差被**放大好几个数量级**。这就是“求逆一个近乎奇异的矩阵”——条件数爆炸，数值上很脆。实测（论文 Fig.2）：同数据同骨干，前向 100% 收敛，逆的几轮就死。

思路 B：直接一步到位。干脆不迭代，学 $v_{ext} \rightarrow n^*$ ，一次前向给出收敛后的基态密度。毛病是它把“**一整个又长又弯的 SCF 轨迹**”**压缩进一次预测**。分布内（小分子）其实不差；但换到更大、更陌生元素的分子，它就把整条轨迹外推崩了（QMugs 上 9.97% vs 前向 2.23%）。

思路 C（本文）：学前向 $v_{KS} \rightarrow n_{out}$ 。它卡在 A 和 B 中间，把两边的毛病都避开：

- **好条件**：不要求逆，直接学那个“弱模态压误差”的前向方向；
- **不挑 XC 泛函**：它只管“给定这个指挥棒，单电子解是什么”，不管这根棒是被 PBE 还是 PBEsol 造的 $\rightarrow$ 换泛函不用重训；
- **误差自纠**：嵌在 SCF 里，中间错了下一轮重算 + 混合拉回来；
- **省数据**：每条参考 SCF 轨迹的**每一轮**都是它的精确样本，只用 5.95 万个标签就够。

CS 的类比：直接预测是 one-shot 出最终答案；前向 KS 像 chain-of-thought——让物理迭代显式存在，模型只负责每步里最简单的子运算。

所以这篇论文**没发明新物理**，它赢在判断对了“该学哪一个映射”，并用**同数据、同骨干、只换目标**的控制实验证明了前向 KS 映射是唯一既稳、又不挑泛函、又省数据、又能自纠的那个。

4 为什么用神经算子，为什么选 FNO

形式匹配 + 卷积定理 先说“神经算子”。普通神经网络学的是“固定长度向量 → 固定长度向量”，输入维度是写死的。但我们要预测的对象是一张 3 维场，而且**网格大小会随体系变**——小分子 20^3 、大晶胞 60^3 。固定维度的网络就不合适了。

神经算子学的是“函数空间 → 函数空间”：输入一个场，输出一个场，**参数不随网格大小变**。而 KS 问题本来就长这样——输入指挥棒 $v_{\text{KS}}(\mathbf{r})$ 这个场，输出密度 $n_{\text{out}}(\mathbf{r})$ 这个场。**形式匹配**，这就是用神经算子的第一层理由（页面上写的）。

那为什么在神经算子里选 **FNO** (Fourier Neural Operator)？因为 KS 里最强的非局部性来自 Hartree 势——它是 $1/r$ 长程相互作用，本质是一个**卷积**：

$$v_{\text{H}}(\mathbf{r}) = \int \frac{n(\mathbf{r}')}{|\mathbf{r} - \mathbf{r}'|} d\mathbf{r}' = (g * n)(\mathbf{r}), \quad g(\mathbf{r}) = \frac{1}{r}. \quad (4)$$

卷积在实空间是“每个点跟每个点算”， $O(N_g^2)$ ，跟 attention 一个毛病。但**谱方法（在频域操作）天生擅长这种全局非局部的映射**——而 KS 势到密度的关系恰恰是强非局部的（一个点的势影响整个密度）。这就是选 FNO 的根本原因。

下面把卷积定理讲透，这是 FNO 的地基。定理一句话：**实空间的卷积 = 频域的逐点相乘**。

$$\widehat{(g * n)}(\mathbf{k}) = \hat{g}(\mathbf{k}) \cdot \hat{n}(\mathbf{k}). \quad (5)$$

证明就两个小动作：

$$\begin{aligned} F[g * n](\mathbf{k}) &= \int \int g(\mathbf{r} - \mathbf{r}') n(\mathbf{r}') e^{-i\mathbf{k} \cdot \mathbf{r}} d\mathbf{r}' d\mathbf{r} \\ &\xrightarrow{\mathbf{u} = \mathbf{r} - \mathbf{r}'} \int \int g(\mathbf{u}) n(\mathbf{r}') e^{-i\mathbf{k} \cdot (\mathbf{u} + \mathbf{r}')} d\mathbf{u} d\mathbf{r}' \\ &= \int \int g(\mathbf{u}) n(\mathbf{r}') \underbrace{e^{-i\mathbf{k} \cdot \mathbf{u}} e^{-i\mathbf{k} \cdot \mathbf{r}'}}_{\text{指数相加} \rightarrow \text{指数相乘}} d\mathbf{u} d\mathbf{r}' \\ &= \left[\int g(\mathbf{u}) e^{-i\mathbf{k} \cdot \mathbf{u}} d\mathbf{u} \right] \left[\int n(\mathbf{r}') e^{-i\mathbf{k} \cdot \mathbf{r}'} d\mathbf{r}' \right] = \hat{g}(\mathbf{k}) \cdot \hat{n}(\mathbf{k}). \end{aligned} \quad (6)$$

就是：**换元把“位置的差”变成“和”，指数律把“和”变回“乘”**，双重积分裂成两个单积分相乘。

再给一个更透的理解：拿一根纯正弦波 $e^{i\mathbf{q} \cdot \mathbf{r}}$ 去跟 g 卷积，出来还是它自己，只被放大 $\hat{g}(\mathbf{q})$ 倍、不掺别的频率——**正弦波就是卷积的“特征波”**。所以傅里叶基把那个 $O(N_g^2)$ 的稠密矩阵**对角化**成“每根频率各乘一个数”。对 $1/r$ 核，那个数是 $\hat{g}(\mathbf{k}) = 4\pi/|\mathbf{k}|^2$ ：低频放大、高频压平——“长程 = 低频被放大”。

最后 FFT 是干嘛的？离散网格上卷积是个循环矩阵，它恒被 DFT 对角化： $C = F^\dagger \text{diag}(\hat{g}) F$ 。算卷积 = “FFT 进对角基 → 乘对角线 → iFFT 回来”，从 $O(N_g^2)$ 降到 $O(N_g \log N_g)$ 。

5 FNO 一层到底在做什么

四步走一遍 FNO 就是“把卷积定理做成一层可学习的网络”。每层四步，输入是场 $z(\mathbf{r})$ （这里就是指挥棒 v_{KS} ）：

- (1) FFT: $z(\mathbf{r}) \rightarrow \hat{z}(\mathbf{k})$ （拆成正弦波，进频域）
- (2) 谱卷积（全局）: $\hat{z}_{\text{out}}(\mathbf{k}) = W_{\theta}(\mathbf{k}) \cdot \hat{z}(\mathbf{k})$ （只动低频，每根波各乘一个可学习数）
- (3) iFFT: $\hat{z}_{\text{out}}(\mathbf{k}) \rightarrow z_{\text{local}}(\mathbf{r})$ （拼回空间）
- (4) 逐点 MLP + 残差（局部）: $z'(\mathbf{r}) = z(\mathbf{r}) + \text{MLP}([z_{\text{local}}(\mathbf{r}), z(\mathbf{r})])$

(7)

逐句说：

- 第 (1)(3) 步就是 FFT / iFFT，进频域再回实空间；
- 第 (2) 步**谱卷积 = 全局混合**：像 attention 的全局 token，但代价是 FFT 级 ($O(N \log N)$ 而非 $O(N^2)$)。 $W_{\theta}(\mathbf{k})$ 就是“可学习的频域权重”。**只动低频**，因为全局物理在低频段，高频留给第 (4) 步；
- 第 (4) 步**逐点 MLP = 局部混合 + 非线性**：每个网格点独立过一个小 MLP，只看自己、不看隔壁，处理局部细节；加回原 z 是残差，保证堆很多层不崩、只学“该修的那点”。

堆 L 层（页面上写的 Lifting $\rightarrow$ Fourier Layers 循环堆叠 $\rightarrow$ Projection），全局 + 局部交替，就够表达“指挥棒 $\rightarrow$ 密度”这个复杂映射。

一句话总结：**FNO 一层 = 先用傅里叶调几根大波的音量（全局协调），再让每个格子各自精修（局部细节），最后把原图加回来打底（残差）。**

6 架构创新：域不变且严格 SE(3) 等变的 FNO

两个改造 标准 FNO 有两个毛病，这篇论文各改了一个，这是它的架构贡献。

第一，域不变 (domain-invariant) ——解决“不同尺寸共用一个模型”。标准 FNO 的滤波器 W_θ 是“**固定形状的矩阵，记住了固定频率的序号**”：它定义在某个固定大小域的频率离散格点上。域一大一小，频率格点就变， W_θ 也得重学——所以不同尺寸的体系没法共用一个模型。

本文改法：模型**不直接学矩阵元素，而是学一个关于真实物理倒空间波矢模长 $|\mathbf{k}|$ 的连续函数**（径向分解）：

$$W_\theta(\mathbf{k}) \rightarrow W_\theta(|\mathbf{k}|). \quad (8)$$

这样无论域多大，都在“物理半径 $|\mathbf{k}|$ ”上采样同一个学到的滤波器 $\rightarrow$ 一套参数横跨分子（小域）和晶体（大域）。类比：标准 FNO 像“按钢琴的键位弹琴”，换钢琴要重学；本文像“按音高分组”，不管钢琴多大，低音区/中音区/高音区各一套参数。

第二，严格 SE(3) 等变——解决“对称性靠数据堆”。页面上那两句合起来：径向对称的滤波器 + 球面模态截断，让谱卷积具备**旋转等变**；再加上逐点 MLP 和周期边界 FFT 天然具备的**平移等变**；合起来就是完整的 **SE(3) 刚体运动等变**：

$$\mathcal{G}(v_{\text{KS}}(\mathbf{R}\mathbf{r} + \mathbf{t})) = \mathcal{G}(v_{\text{KS}})(\mathbf{R}\mathbf{r} + \mathbf{t}), \quad \forall \mathbf{R} \in SO(3), \mathbf{t} \in \mathbb{R}^3. \quad (9)$$

意思是：把分子整体转一下或挪一下，预测的密度就跟着转/挪，**不靠数据增强**。

- “截断做成圆球”：严格只保留最大频域半径以内的波，把方盒子切成正圆球，消除了网格轴向的人造各向异性（不然沿 x 轴和沿对角线的波会被区别对待）；
- “刚好不需要学习方向性”：方向性交给残差网络去拟合，谱部分只管半径上的径向结构。

那页面上那句“**拟合能力下降也无所谓，交给 SCF 兜底**”是什么意思？等变是一种“结构先验”——你把对称性写进网络，网络就**不用靠数据去学对称性**，代价是单层的拟合灵活性略降。但因为我们把 FNO 嵌在 SCF 迭代里，中间某层拟合得不完美，下一轮会重算、混合会拉回来——**物理迭代给模型的结构先验兜了底**。所以“等变带来的这点拟合力损失”是可接受的。

7 最终效果

把数字念出来 最后说效果。这张页面上两句 + 一张标度图，对应三件事：

一，超大体系单 GPU。模型在**单块 NVIDIA B300 GPU**上，成功自治收敛了含**8,250 个镁原子 (82,500 个价电子)**的锥面螺位错体系。作个对比：同一个类位错问题，2019 年拿 Gordon Bell 提名的 DFT-FE 算法，6,164 个原子就要 56 轮 SCF $\times$ 1,300 节点 (7,800 块 V100)；最大的 10,508 原子要 3,800 节点 (22,800 GPU) 才跑一轮。这篇用一块 GPU 收敛了同量级的体系，打破了传统 DFT 动辄几千块 GPU 的算力壁垒。

二，准线性标度 (就是那张图)。横轴是网格点数 N_g ，纵轴是每轮 SCF 的时间，log-log 轴。传统 Quantum ESPRESSO 拟合出来是 $t \propto N_g^{3.37}$ ($\approx$ 立方)，Kohn-Sham FNO 是 $t \propto N_g^{1.03}$ ($\approx$ 线性)。体系大一倍，QE 贵约 8 倍，FNO 只贵约 2 倍——**这才是能推到介观尺度的关键。**

三，精度没掉。换到收敛密度后做一次固定密度的 post-SCF 对角化，能带、带隙、DOS、状态方程这些观测量都接近 KS-DFT 精度：比如 CaTiO_3 带隙 DFT 2.573 eV、FNO 2.469 eV；金属 Sr_3SnO 总能量差 2.29 meV/atom。而且**换 XC 泛函不用重训** (PBE $\rightarrow$ PBEsol，平衡体积差 0.61%)。

一句话收尾：**这篇论文没发明新物理，它是在 DFT 的自治循环里，精准地把最贵的那一步 (对角化) 换成一个好条件、不挑泛函、省数据、能自我纠错的前向神经算子**，从而第一次让免轨道的 SCF 在分子、金属、绝缘体上都收敛，并在单块 GPU 上推到 8 万电子。

我讲完了，谢谢大家。

Q：为什么最后还要做一次对角化？不是收敛了吗？ 收敛的是**密度** n^* ，但能带、总能量住在**轨道/特征值**那一层。FNO 只产密度，要读能级得拿收敛密度再解一次 KS 方程 (post-SCF)，这次是**一次性的**，不是循环里那种反复做的，所以便宜。

Q：FNO 怎么处理 3D 场？和普通网络差在哪？ 输入是 $N_x \times N_y \times N_z$ 的 3D 数组。普通 MLP 把它拉平、每个点连每个点 ($O(N^2)$ 且无空间先验)；CNN 用滑动小窗只看邻居 (要看全局得堆很多层)；attention 每点跟每点算权重 ($O(N^2)$)。**FNO 是 3D FFT 跳到频域、每根低频波各自用一个可学习矩阵处理、再 iFFT 回来**——信息混合发生在**频率空间**不在空间点之间， $O(N \log N)$ ，而且 $1/r$ 卷积本来就在频域是逐点乘，结构天然匹配。

Q：为什么不能写成一个矩阵 (像四元数那样自动一致)？ 可以，就是**密度矩阵** ρ 。 $n_{\text{out}} = \rho(\mathbf{r}, \mathbf{r})$ 读对角线， $T_s = \text{Tr}[\hat{T}\rho]$ 读迹，一致性由 ρ 的代数 (幂等、对易 $\hat{h}_{\text{KS}}$) 自动保证，像四元数“轴 + 角内禀”。但 ρ 是 N_g^2 的矩阵，“对角化它”就是 $O(N_g^3)$ ——**等于把要去掉的对角化又搬回来了**。所以本文的取舍是：只输出对角线 $n(\mathbf{r})$ ($O(N_g \log N_g)$)，一致性暂时用一次精确 post-SCF 解顶上，彻底免轨道是下一步 (学前向动能 T_s)。